

Diffusion model

Denoising Diffusion Probabilistic Models

Introduction

- 기존에 GANs, Flows, VAEs, autoregressive models 등의 모델들이 이미지 및 음성 합성에 대해 좋은 결과를 보임
- Diffusion 모델은 유한한 시간 후 데이터와 일치하는 샘플을 생성하도록 학습된 파라미터화된 마르코프 연쇄(Markov Chain)
- 마르코프 연쇄의 전이는 샘플링 과정의 반대 방향으로 데이터에 점진적으로 노이즈를 추가하는 diffusion process를 되돌리는 방식으로 학습
- diffusion process가 작은 양의 가우시안 노이즈로 구성되어 있다면, sampling chain의 전이 또한 conditional Gaussian으로 설정 가능
- 이로 인해 매우 단순한 신경망 파라미터화 가능
- 이 논문에서는 확산 모델이 실제로 고품질 샘플을 생성할 수 있으며, 때로는 다른 생성 모델들의 공개된 결과보다도 더 우수한 성능을 보일 수 있음을 보여줌
- 디퓨전 모델의 특정한 파라미터화 방식을 통해, 학습 과정에서는 다중 노이즈 수준에서의 denoising score matching, 샘플링 과정에서는 annealed Langevin dynamics 와 이론적으로 동등함을 보임을 확인
- 모델의 로그 가능도는 에너지 기반 모델이나 score matching에서 사용된 annealed importance sampling의 큰 추정값보다 나은 수준
- lossless codelength가 사람이 인지하지 못할 수준의 이미지 디테일을 설명하는 데 사용된다는 것을 발견
- diffusion model의 sampling 절차가 progressive decoding (autoregressive model의 bit 단위 디코딩처럼 동작) 형태임을 보여줌

Diffusion models and denoising autoencoders

diffusion model은 겉으로 보기엔 latent variable 모델의 제한된 형태처럼 보일 수 있지만, 실제 구현에서는 매우 다양한 설계 선택 가능

- 정방향 과정(forward process)의 분산 β_t
- 역방향 과정(reverse process) 의 모델 아키텍처 및 조건부 가우시안 파라미터화 방식

이 선택들을 잘 정하기 위해, diffusion model과 denosing score matching 간의 명확한 이론적 연결을 새롭게 정립

weighted variational bound를 목적 함수로 갖는 간단한 구조

3.1 Forward process and L_T

분산 β_t 를 learnable에서 fixed scheduling으로 변경

이러한 설정에서는 근사 posterior 분포 q 는 학습 파라미터가 없는 분포

결과적으로 L_T 항은 훈련 중 상수로 처리할 수 있고 무시해도 됨

3.2 Reverse process and $L_{1:T-1}$

조건부 확률 정의

이 형태로 역방향 분포 정의 L_0

$$p_\theta(x_{t-1} | x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_t)$$

각 시간 t 에 대해 조건부 가우시안 분포를 모델링

- 분산(Σ_t) 은 사전 설정된 time-dependent 상수
- 평균(μ_t) 은 학습 가능한 신경망이 예측

분산(Σ_t) 선택

분산 σ_t^2 은 두 가지 후보가 실험적으로 유사한 결과

- $\sigma_t^2 = \beta_t$ ($x_0 \sim \mathcal{N}(0, I)$)일 때 최적
- $\sigma_t^2 = \beta_t(1 - \alpha_{t-1}) / (1 - \alpha_t)$ (x_0 이 하나의 고정된 점일 때 최적)

각각 역방향 엔트로피의 상하한에 대응

평균(μ_t) 파라미터화

L_t 항을 유도하여, 평균 μ_t 예측을 위한 parameterization을 다음과 같이 선택

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \alpha_t}} \cdot \epsilon_\theta(x_t, t) \right)$$

- $\epsilon_\theta(x_t, t)$ 는 모델이 예측하는 노이즈
- 이 파라미터화 방식은 ϵ -prediction parameterization

Algorithm 1 Training

```

1: repeat
2:    $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ 
3:    $t \sim \text{Uniform}(\{1, \dots, T\})$ 
4:    $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
5:   Take gradient descent step on
      $\nabla_{\theta} \|\epsilon - \epsilon_{\theta}(\sqrt{\alpha_t}\mathbf{x}_0 + \sqrt{1 - \alpha_t}\epsilon, t)\|^2$ 
6: until converged

```

Algorithm 2 Sampling

```

1:  $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
2: for  $t = T, \dots, 1$  do
3:    $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  if  $t > 1$ , else  $\mathbf{z} = \mathbf{0}$ 
4:    $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \alpha_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$ 
5: end for
6: return  $\mathbf{x}_0$ 

```

- 샘플링 방식은 Langevin dynamics 와 유사
- ϵ -prediction 파라미터화는 denoising score matching over multiple noise levels 와 이론적으로 동등

3.3 Data scaling, reverse process decoder, and L_0

이미지 데이터를 0~255의 정수에서 [-1, 1]로 정규화한 형태로 처리

이렇게 하면 역방향 과정의 신경망이 항상 일관된 범위의 입력을 다루게 되어 학습이 안정화
 샘플링이 완료되면 마지막에 다음과 같은 독립 디코더를 적용

여기서 μ_i 는 x_1 으로부터 계산된 평균값

$$p_{\theta}(x_0 | x_1) = \prod_{i=1}^D \int_{x_i - \frac{1}{255}}^{x_i + \frac{1}{255}} \mathcal{N}(x; \mu_i, \sigma^2) dx$$

이 방식은 VAE 및 autoregressive 모델에서도 쓰이는 continuous-discretized likelihood 방식과 유사

3.4 Simplified training objective

앞에서 정의한 역방향 과정(p_{θ}) 과 디코더($p_{\theta}(x_0|x_1)$) 를 바탕으로 구성된 variational bound는 θ (모델 파라미터)에 대해 미분 가능하고 학습에 바로 활용 가능

변형된 변분 하한식을 사용하는 것이 샘플 품질 측면에서 더 유리하고, 구현 또한 단순

$$L_{\text{simple}}(\theta) := \mathbb{E}_{t, x_0, \epsilon} \left[\|\epsilon - \epsilon_{\theta}(x_t, t)\|^2 \right]$$

- $t = 1$ 인 경우: 디코더 항(L_0) 에 대응,
정수 기반 픽셀의 구간 확률(integral) 대신, 가우시안 밀도 함수 $\times$ bin 너비로 근사, 분산(σ_1^2) 및 경계 효과(edge effects)는 무시
- $t > 1$ 인 경우: 비가중 평균(unweighted version) 으로 해석, NCSN (Noise Conditional Score Network)에서 사용된 denoising score matching loss와 유사

- L_T 항: 정방향 과정의 분산 β_t 를 고정했기 때문에 L_T 항은 무시