

FCN

Abstract

- 기존 CNN을 end-to-end로 학습하고, pixel-to-pixel 예측이 가능하도록 변형하여 입력 이미지 크기에 상관없이 대응되는 크기의 출력을 생성할 수 있는 구조를 설계 → SOTA 달성
- 주된 아이디어는 "fully convolutional" 네트워크를 구축함으로써, 다양한 사이즈의 인풋으로부터 상응하는 output을 효과적으로 추론하고 학습하게 만드는 것
- 기존 분류 네트워크(AlexNet, VGG, GoogLeNet)를 Fully Convolutional 구조로 재 설계하고, fine-tuning을 통해 세분화(segmentation) 작업에 적응

Introduction

- ConvNet은 classification에서 시작해 object detection, part/keypoint prediction, local correspondence 등으로 발전함
- 본 논문은 픽셀 단위 예측을 위한 최초의 end-to-end 학습 방식을 제안하며, supervised pre-training을 활용
- 기존 네트워크는 coarse한 feature map을 생성하지만, FCN은 upsampling을 통해 입력과 동일한 크기의 dense output을 만들
- 전체 이미지 단위로 학습 및 추론이 가능하여 patch 단위 학습보다 효율적이며, 전처리나 후처리 없이 segmentation 가능함
- Skip 구조를 통해 deep layer의 semantic 정보와 shallow layer의 fine한 위치 정보를 효과적으로 결합

Fully convolutional networks

- convnet의 각 레이어의 output은 $h \times w \times d$ 의 사이즈를 갖는 3차원 array
- Convnets은 기본 구성요소(Convolution, pooling, activation functions)는 Local input 영역에서 작동하고, 해당되는 공간 좌표에만 영향을 받기 때문에 내재적으로 translation invariant

3.1 Adapting classifiers for dense prediction

- LeNet, AlexNet과 같은 recognition 신경망은 fixed-sized 입력값을 받아서 공간정보가 없는 출력값 생성
- 하지만 fully connected layer를 convolution으로 해석하면, 입력 크기와 무관하게 작동하는 FCN 구조로 변환 가능
- 이렇게 변환하면 이미지를 patch로 나누지 않고도 dense output map 생성 가능

e.g. AlexNet은 227×227 입력에 12ms 걸리지만, FCN으로 바꾸면 500×500 입력에 대해 10×10 grid 출력까지 22ms로 효율적

- 추론과 역전파 모두 빠르고 효율적이며, segmentation처럼 픽셀 단위 ground truth가 있는 작업에 적합
- 단점은 subsampling으로 인해 출력 해상도가 입력보다 줄어듦

3.2. Shift-and-stitch is filter rarefaction

- Shift-and-Stitch는 OverFeat에서 제안된 방식으로, 출력을 밀집하게(dense) 만드는 테크닉
- 입력을 여러 번 조금씩 이동시켜(convnet 통과), 그 결과를 interlace해 고해상도 출력을 얻음
- receptive field의 stride를 줄이지 않고도 출력을 조밀하게 만들 수 있다는 장점
- 실험적으로 shift-and-stitch보다 upsampling + skip connection 방식이 더 효과적임을 확인

3.3. Upsampling is backwards strided convolution

- 업샘플링(upsampling)은 coarse한 출력을 원래 해상도로 복원하기 위한 방법
- 일반적인 보간법(bilinear interpolation) 대신, FCN에서는 Deconvolution (또는 Transposed Convolution)을 사용
- Deconvolution은 stride를 반대로 적용한 convolution으로 볼 수 있고, 출력 해상도를 확대
- Deconvolution filter는 단순 보간처럼 고정된 값이 아니라, 학습 가능한 파라미터로 설정 가능
- 여러 개의 deconvolution 층과 비선형 활성화를 쌓으면 비선형적인 복잡한 업샘플링도 학습 가능

- 실험을 통해 in-network deconvolution이 빠르고 효과적이라는 것을 확인했고, 이후 skip 구조와 결합해 사용

3.4. Patchwise training is loss sampling

- 패치 단위 학습(patchwise training)과 전체 이미지 학습(fully convolutional training)은 모두 같은 데이터 분포를 만듦
- Fully convolutional training은 patchwise training에서 모든 receptive field를 한 배치로 처리한 것과 동일
- Patchwise 학습은 더 많은 배치 구성이 가능하지만, 전체 이미지 학습이 계산적으로 더 효율적
- Patchwise sampling은 클래스 불균형 보정과 공간적 상관성 완화에 도움
- 실험 결과, sampling이 학습 속도나 성능 향상에 효과적이지 않았고, 전체 이미지 학습이 더 빠르고 효과적

4. Segmentation Architecture

기존 ILSVRC 분류 네트워크(AlexNet, VGG 등)를 FCN으로 변환하고, in-network upsampling과 픽셀 단위 loss 를 추가해 segmentation에 적용

semantic (coarse) 정보와 appearance (fine) 정보를 결합하는 skip 구조를 새롭게 제안

4.1. From classifier to dense FCN

- AlexNet, VGG-16, GoogLeNet 같은 성공적인 분류 네트워크를 FCN으로 변환하여 사용
- 가장 우수한 결과를 낸 모델은 VGG-16 기반 FCN (FCN-VGG16)임

변환 방식:

- 마지막 분류층 제거 (decapitation)
- fully-connected 층을 convolution으로 대체
- 1×1 convolution을 추가해 PASCAL VOC 에 대한 점수 출력
- 이어서 deconvolution layer를 추가해 coarse output을 pixel-level로 업샘플링

4.2. Combining what and where

- 기본 FCN (e.g., FCN-32s)은 출력 stride가 32로 해상도가 매우 낮아 coarse output을 만들
- 상위 layer(conv7)의 예측을, 하위 layer(pool4, pool3)의 예측과 결합해 출력 정밀도를 향상시킴

구조

- **FCN-16s** : conv7 + pool4 결합 (stride 16 출력) → **mean IU 62.4** (+3.0 향상)
- **FCN-8s** : 위 구조에 pool3 추가 결합 (stride 8 출력) → **mean IU 62.7**
- 이 구조는 skip connection을 통해 semantic 정보(coarse)와 appearance 정보(fine)를 함께 활용
- 각 skip 연결은 1×1 conv + upsampling으로 구성되며, end-to-end로 학습

Conclusion

- Fully Convolutional Networks (FCNs)는 현대 분류용 ConvNet을 포함하는 더 일반적인 모델 클래스
- 기존 분류 네트워크를 FCN으로 확장하고, multi-resolution layer 결합(skip structure)을 통해 semantic segmentation 성능을 대폭 향상
- 제안한 구조는 학습과 추론을 동시에 단순화하면서도 가속화하여, 속도와 정확도 모두에서 기존 SOTA를 능가