

SAM

Segment Anything

Introduction

Web-scale datasets로 pre-trained된 LLM은 NLP에서 zero-shot 및 few-shot 일반화 성능을 통해 자연어처리 분야에 혁신적

이러한 foundation models 은 학습 중에 보지 못한 과제나 데이터에도 일반화 가능

Vision 분야에서는 CLIP, ALIGN 같은 foundation model이 있으며, 이들은 text와 image 인코더를 두 개의 modalities를 align하는 contrastive learning을 사용하여 학습
본 논문에서 우리는 이미지 분할(image segmentation)을 위한 foundation model을 구축하는 것을 목표

이를 위해 promptable model을 발전시키고, 방대한 데이터셋으로 pre-train하여 일반화 성능 제공

과제(task), 모델(model), 데이터(data)의 세 가지 구성 요소에 달려있음

- 제로샷 일반화를 가능하게 하는 **Task**는 무엇인가?
- 이에 상응하는 **Model** 아키텍처는 무엇인가?
- 이 과제와 모델을 학습시키기 위한 **Data**는 무엇인가?

강력한 pre-training objective 를 제공하면서 동시에 다양한 다운스트림 활용이 가능한 promptable segmentation task 를 정의


프롬프트를 받으면 실시간으로 분할 마스크를 출력할 수 있어 인터랙티브한 사용이 가능해야함

Model 학습을 위해 diverse, large-scale source of data를 사용하며, segmentation을 위한 web-scale data source가 없었기 때문에, data engine을 만들

Task.

최근 NLP는 프롬프트 기법을 통해 구현, 이에 영감을 받아 promptable segmentation task 제안

목표는 어떤 형태의 segmentation prompt가 주어졌을 때, 그에 대응하는 valid segmentation mask 를 반환



(a) **Task:** promptable segmentation


- 프롬프트는 이미지 내에서 무엇을 분할할 지를 명시(공간 정보, 텍스트 정보)

프롬프트 기반 분할 과제를 사전학습 목표로 삼고, 프롬프트 엔지니어링을 통해 일반적인 다운스트림 분할 과제에도 활용

Model.

프롬프트 기반 분할 과제와 실제 환경에서의 활용 목표는 모델 아키텍처에 다음과 같은 제약을 부여

- 프롬프트의 유연한 수용, 실시간 상호작용이 가능한 분할 마스크 출력, 그리고 모호성 인식(ambiguity-aware) 능력
- 단순한 구조가 이 세 가지 조건을 모두 충족



(b) **Model:** Segment Anything Model (SAM)

- 이미지 인코더는 이미지 임베딩 계산
- 프롬프트 인코더는 프롬프트 임베딩
- 이 두 정보를 결합하여 경량의 마스크 디코더가 분할 마스크 예측


- SAM을 이미지 인코더와 빠른 프롬프트 인코더/마스크 디코더로 분리함으로써, 동일한 이미지 임베딩을 다양한 프롬프트에 대해 재사용할 수 있어 연산 비용 줄임
- 주로 점, 박스, 마스크 형태의 프롬프트를 사용하며, 자유형 텍스트 프롬프트 결과도 제시
- SAM의 모호성 인식 가능하게 하기 위해, 하나의 프롬프트에 대해 복수의 마스크를 예측하도록 설계

Data engine.

새로운 데이터 분포에 대해 강력한 일반화를 달성하기 위해서는 기존의 분할 데이터셋보다 더 크고 다양한 마스크 데이터 필요

마스크는 자연적으로 풍부하지 않기 때문에 전략 필요

- 모델과 함께 발전하는 data engine 구축



(c) Data: data engine (top) & dataset (bottom)

- 이는 모델을 데이터셋 주석에 직접 활용하는 루프 구조를 가짐
- 1단계: **보조 수동(annotation-assist)** – SAM이 기존의 인터랙티브 분할 도구처럼 주석을 지원
- 2단계: **반자동(semi-automatic)** – SAM이 가능한 객체 위치에 대해 마스크를 생성하고, 나머지는 사람이 주석
- 3단계: **완전 자동화(full automatic)** – SAM을 통해 전경(foreground) 점들에 대해 정규격 그리드 프롬프트를 수행, 평균적으로 이미지당 약 100개의 고품질 마스크를 생성

Segment Anything Task

Task.

우리는 프롬프트(prompt)의 개념을 NLP에서 이미지 분할로 확장하였다. 여기서 프롬프트는 다음과 같은 형태가 될 수 있다:

- 전경/배경 포인트(foreground/background points)
- 대략적인 박스(box) 또는 마스크(mask)
- 자유 형식의 텍스트(free-form text)
- 혹은 일반적으로 이미지 내에서 **무엇을 분할할 것인지**를 지정하는 모든 정보

promptable segmentation task란, 어떤 프롬프트가 주어지든 이에 대응하는 유효한 분할 마스크를 반환하는 것 의미

'valid mask'란 프롬프트가 모호해서 여러 객체를 지시할 수 있는 경우에도 그 중 하나에 대해 합리적인 마스크를 출력해야 함

⇒ 언어 모델이 모호한 프롬프트에 대해서도 일관된 응답을 생성하는 것과 유사한 요구조건

Pre-training.

모델이 예측한 마스크를 정답 마스크(GT)와 비교하는 형태의 학습 알고리즘 유도

목표는 모든 프롬프트에 대해 항상 유효한 마스크를 예측하는 것

Segment Anything Model




Figure 4: Segment Anything Model (SAM) overview. A heavyweight image encoder outputs an image embedding that can then be efficiently queried by a variety of input prompts to produce object masks at amortized real-time speed. For ambiguous prompts corresponding to more than one object, SAM can output multiple valid masks and associated confidence scores.

SAM은 image encoder, flexible prompt encoder, fast mask decoder 세 가지 구성 요소로 이루어짐

Image Encoder

확장성과 강력한 사전학습 방법을 고려하여, MAE로 사전학습된 ViT 사용

이는 고해상도 입력을 처리하도록 최소한으로 수정

이미지 인코더는 이미지 당 한번만 실행되며, 프롬프트 이전에 미리 적용될 수 있음

Prompt Encoder

두 가지 유형을 프롬프트 고려함

sparse prompts : 점(points), 박스(boxes), 텍스트(text)

dense prompts : 마스크(masks)

점과 박스는 positional encoding에 각 프롬프트 타입에 대한 학습된 임베딩을 더해서 표현

자유 형식의 텍스트 프롬프트는 CLIP의 텍스트 인코더를 그대로 사용

마스크 형태의 dense 프롬프트는 convolution 연산을 통해 임베딩, 이미지 임베딩과 element-wise sum

Mask Decoder

이미지 임베딩, 프롬프트 임베딩, 출력 토큰을 받아 효율적으로 마스크 생성

이 구조는 Transformer 디코더 블록을 수정해 적용, 뒤에 dynamic mask prediction head 붙음

수정된 디코더 블록은 prompt self-attention 과 cross-attention을 두 방향(prompt to image) 모두에 적용하여 임베딩 업데이트

블록 2개 거친 후, 이미지 임베딩은 업샘플링되고 MLP가 출력 토큰을 동적 선형 분류기로 매핑

이 분류기는 이미지의 각 위치에서 foreground probability 예측

Segment Anything Data Engine

분할 마스크는 웹 상에 풍부하게 존재하지 않기 때문에, 자체적으로 SA-1B 데이터셋을 구축하기 위한 데이터 엔진 설계

1단계 : Assited-manual Stage

- 초기 단계는 classic interactive segmentation과 유사하게 구성
- 웹 브라우저 상의 SAM 기반 툴을 사용하여 전경/배경 클릭 기반으로 마스크를 생성하고, 브러시와 지우개로 정밀하게 수정
- 객체의 의미적 제약(semantic constraint)은 없었고, stuff(재료, 배경 등)과 things(개체) 모두 자유롭게 라벨링할 수 있음
- 주석 시간은 30초 이상 소요될 경우 다음 이미지로 넘어가도록 유도
- 이 시점의 SAM은 공개 분할 데이터셋으로 사전학습되었고, 이후 새로 수집된 마스크로 재학습 (6번 거침)

2단계: Semi-automatic Stage

- 이 단계의 목표는 다양성 증가
- 더 눈에 띄지 않는 객체를 주석자가 처리할 수 있도록, 먼저 confident 마스크를 자동 예측
- 예측된 마스크를 미리 채워넣은 이미지를 주석자에게 보여주고, 추가로 주석할 객체만 수작업으로 처리
- 이를 위해 1단계 마스크를 기반으로 일반 "object" 카테고리 바운딩 박스 감지기를 학습
- 주기적으로 5회에 걸쳐 모델을 재학습

3단계: Fully Automatic Stage

- 주석자가 전혀 개입하지 않는 완전 자동화가 이루어짐
- 가능한 두 가지 요인은 앞선 단계에서 수집된 다양한 마스크로 모델이 충분히 향상되었고, ambiguity-aware 모델이 개발되어 모호한 경우에도 유효한 마스크를 생성 가능
- 32×32 그리드의 포인트를 모델에 프롬프트로 제공하고, 각 포인트에 대해 유효한 객체 마스크 세트를 예측
- 포인트가 부분 또는 세부 부분에 있을 경우, 모델은 subpart, part, whole object를 모두 반환